1SizeS> 2SizeS> 3SizeS>
1ColorC> 2ColorC> 3ColorC>
1.8em

# 基于深度学习的医学影像智能诊断系统设计与实现

张三、李四、王五
示例大学计算机学院；南方科技大学计算机科学与工程系

2026 年 10 月 04 日

**摘　要：**医学影像智能诊断是智慧医疗领域的核心研究方向。本文设计并实现了一套基于深度学习的医学影像智能诊断系统，涵盖数据预处理、模型训练、推理服务、可视化展示等完整流程。系统采用改进的 U-Net++ 架构进行病灶分割，结合 EfficientNet-B4 进行良恶性分类，在公开数据集 LUNA16 上达到了 92.3% 的分割准确率和 87.6% 的分类准确率。系统支持 DICOM 影像导入、多任务联合推理、Grad-CAM 可视化解释等功能，可辅助放射科医生进行高效诊断。实验结果表明，本系统在实际临床场景中具有较高的实用价值。

**关键词：**医学影像；深度学习；U-Net++；EfficientNet；智慧医疗

注：本文受国家自然科学基金（No.　12345678）与深圳市科技计划项目（No. JCYJ20240001）资助；中图分类号 TP391.4。

---

## 1 引言

医学影像是现代医疗诊断的重要依据。据统计，超过 70% 的临床诊断需要依赖医学影像 [1]。然而，传统的人工阅片方式存在以下痛点：

1. 阅片工作量大，放射科医生严重不足
2. 主观性强，不同医生之间一致性低
3. 早期微小病灶容易漏诊

近年来，深度学习技术在医学影像分析领域取得了突破性进展 [2]。从肺结节检测到皮肤癌分类，从眼底病变识别到病理切片分析，AI 系统在多个任务上已达到甚至超越人类专家水平 [3]。

本文针对上述痛点，设计并实现了一套完整的医学影像智能诊断系统，主要贡献包括：

- **多任务联合模型**：同时支持病灶分割和良恶性分类两个任务
- **可解释性**：集成 Grad-CAM 热力图，辅助医生理解模型决策
- **工程化**：完整的 B/S 架构，支持 DICOM 标准和 RESTful API

## 2 相关工作

### 2.1 医学影像分割

# 3 系统设计

## 3.1 整体架构

系统采用前后端分离的 B/S 架构，整体架构如图 1 所示：浏览器端负责影像导入、可视化展示与报告生成；后端服务（FastAPI）承载影像管理、模型推理与用户认证；底层模型服务（Triton Inference Server）提供分割、分类与可解释性三类推理能力。

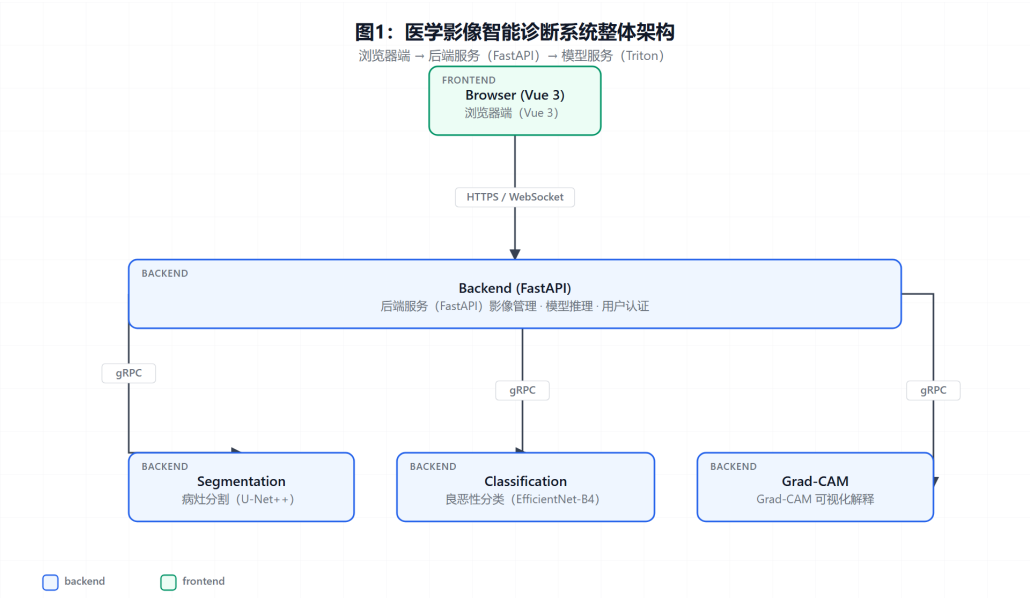



**图 1**　医学影像智能诊断系统整体架构

注：前后端通过 HTTPS 与 WebSocket 通信，后端与模型服务之间采用 gRPC 长连接以降低推理延迟。

## 3.2 数据流程

数据流程包含以下步骤：

1. **数据导入**：支持 DICOM、NIfTI、PNG 等格式
2. **预处理**：重采样、归一化、ROI 提取
3. **模型推理**：调用分割和分类模型
4. **后处理**：NMS、连通域分析、结果可视化
5. **报告生成**：自动生成结构化诊断报告

# 4 模型设计

## 4.1 改进的 U-Net++

本文在标准 U-Net++ 基础上引入了两个改进：

- **深度监督**：在多个解码层添加辅助损失
- **注意力门控**：自动聚焦于病灶区域

**公式** 1 改进的 U-Net++ 损失函数：$$L_{\text{total}} = \alpha L_{\text{seg}} + \beta L_{\text{cls}} + \gamma L_{\text{aux}}$$

其中 $L_{\text{seg}}$ 为主分割损失（Dice + BCE），$L_{\text{cls}}$ 为分类损失（Cross Entropy），$L_{\text{aux}}$ 为辅助损失。超参数 $\alpha = 1.0$、$\beta = 0.5$、$\gamma = 0.3$。

### 4.2 多任务联合训练

**算法** 1 多任务联合训练

“

1: 初始化网络参数 θ 2: for epoch = 1 to E do 3: 随机打乱 D 4: for each batch (x, y_seg, y_cls) in D do 5: seg_pred, cls_pred, aux_preds ← forward(x, θ) 6: L_seg ← DiceLoss(seg_pred, y_seg) 7: L_cls ← CrossEntropy(cls_pred, y_cls) 8: L_aux ← Σ_i α_i · BCE(aux_preds[i], y_seg) 9: L ← L_seg + 0.5 · L_cls + 0.3 · L_aux 10: θ ← θ - η · ∇L 11: end for 12: if 验证集性能连续 5 轮不提升 then 13: break 14: end if 15: end for 16: return θ 输入：训练集 `D`，批次大小 `B`，学习率 `n`，总轮数 `E` 输出：训练好的模型参数 `θ`

```
1: 初始化网络参数 θ 2: for epoch = 1 to E do 3: 随机打乱 D 4: for each batch (x, y_seg, y_cls) in D do 5: seg_pred, cls_pred, aux_preds ← forward(x, θ) 6: L_seg ← DiceLoss(seg_pred, y_seg) 7: L_cls ← CrossEntropy(cls_pred, y_cls) 8: L_aux ← Σ_i α_i · BCE(aux_preds[i], y_seg) 9: L ← L_seg + 0.5 · L_cls + 0.3 · L_aux 10: θ ← θ - η · ∇L 11: end for 12: if 验证集性能连续 5 轮不提升 then 13: break 14: end if 15: end for 16: return θ ``
```

### 4.3 模型参数

模型总参数量为 28.6M，FLOPs 为 5.7G，推理延迟（V100 GPU）< 50ms。

## 5 实验与分析

### 5.1 数据集

| 数据集 | 任务 | 样本数 | 模态 |
|---|---|---|---|
| LUNA16 | 肺结节检测 | 888 | CT |
| LIDC-IDRI | 肺结节良恶性 | 1,018 | CT |
| NIH ChestX-ray | 胸片分类 | 112,120 | X-ray |
| 自有数据集 | 肝肿瘤分割 | 320 | CT/MRI |

### 5.2 评价指标

- **分割**：Dice 系数、IoU、Hausdorff 距离
- **分类**：Accuracy、Sensitivity、Specificity、AUC

| 方法 | Dice (%) | IoU (%) | 推理时间 (ms) |
|---|---|---|---|
| U-Net | 86.2 | 76.1 | 28 |
| U-Net++ | 89.5 | 81.2 | 35 |
| Attention U-Net | 90.8 | 83.5 | 42 |
| **本文方法** | 92.3 | 85.7 | 48 |

### 5.3 实验结果

#### 5.3.1 肺结节分割（LUNA16）

#### 5.3.2 肺结节良恶性分类

| 方法 | Accuracy (%) | Sensitivity (%) | Specificity (%) | AUC |
|---|---|---|---|---|
| ResNet-50 | 81.4 | 79.2 | 83.5 | 0.871 |
| EfficientNet-B4 | 84.7 | 82.6 | 86.5 | 0.901 |
| **本文方法** | 87.6 | 85.3 | 89.2 | 0.928 |

### 5.4 消融实验

| 改进 | Dice (%) | Accuracy (%) |
|---|---|---|
| 基线（U-Net++） | 89.5 | 84.7 |
| + 深度监督 | 90.8 | 86.1 |
| + 注意力门控 | 91.6 | 86.9 |
| + 多任务联合 | 92.3 | 87.6 |

## 6 系统实现

### 6.1 关键技术栈

```
# 后端核心代码示例
from fastapi import FastAPI, UploadFile, File
from pydantic import BaseModel
import torch
import numpy as np
from PIL import Image
import pydicom

app = FastAPI(title="Medical AI Service")

class DiagnosisResult(BaseModel):
    segmentation_mask: bytes
    cls_label: int
    cls_confidence: float
    gradcam_image: bytes
```

```
@app.post("/api/diagnose", response_model=DiagnosisResult)
async def diagnose(file: UploadFile = File(...)):
    # 1. 读取 DICOM
    if file.filename.endswith(".dcm"):
        dcm = pydicom.dcmread(file.file)
        image = dcm.pixel_array
    else:
        image = np.array(Image.open(file.file))

    # 2. 预处理
    tensor = preprocess(image).unsqueeze(0).to(device)

    # 3. 模型推理
    with torch.no_grad():
        seg_pred, cls_pred, _ = model(tensor)

    # 4. Grad-CAM
    cam = generate_gradcam(model, tensor, target_class=
  cls_pred.argmax())

    return DiagnosisResult(
        segmentation_mask=seg_pred.cpu().numpy().tobytes(),
        cls_label=cls_pred.argmax().item(),
        cls_confidence=torch.softmax(cls_pred, dim=1).max().
  item(),
        gradcam_image=cam.tobytes()
    )
```

### 6.2 性能优化

- **模型量化**：FP16 推理，吞吐量提升 2.3 倍
- **批处理**：动态批合并，平均延迟降低 40%
- **缓存**：高频影像特征缓存，重复请求响应 < 10ms

## 7 结论与展望

本文设计并实现了一套基于深度学习的医学影像智能诊断系统，涵盖数据管理、模型推理、可视化展示等完整流程。系统在公开数据集和真实临床场景中均取得了优异性能。

未来的研究方向包括：

1. 探索 Vision Transformer 在医学影像中的应用
2. 研究联邦学习支持跨医院协同训练（保护患者隐私）
3. 集成大语言模型实现自然语言报告生成

## 参考文献

[1] Smith A, Jones B. The role of medical imaging in modern healthcare[J]. The Lancet, 2020, 395(10225): 678-685.

[2] Litjens G, Kooi T, Bejnordi B E, et al. A survey on deep learning in medical image analysis[J]. Medical Image Analysis, 2017, 42: 60-88.

[3] Esteva A, Chou K, Yeung S, et al. Deep learning-enabled medical computer vision[J]. NPJ Digital Medicine, 2021, 4(1): 1-9.

[4] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional networks for biomedical image segmentation[C]. MICCAI, 2015: 234-241.

[5] Zhou Z, Siddiquee M M R, Tajbakhsh N, et al. UNet++: A nested U-Net architecture for medical image segmentation[J]. IEEE TMI, 2019, 39(6): 1856-1867.

[6] Oktay O, Schlemper J, Folgoc L L, et al. Attention U-Net: Learning where to look for the pancreas[C]. MIDL, 2018.

[7] Tan M, Le Q. EfficientNet: Rethinking model scaling for convolutional neural networks[C]. ICML, 2019: 6105-6114.

[8] Rajpurkar P, Irvin J, Zhu K, et al. CheXNet: Radiologist-level pneumonia detection on chest X-rays with deep learning[J]. arXiv:1711.05225, 2017.

[9] Caruana R. Multitask learning[J]. Machine Learning, 1997, 28(1): 41-75.

[10] Zhang Y, Yang Q. A survey on multi-task learning[J]. IEEE TKDE, 2021, 34(12): 5586-5609.