

基于深度学习的医学影像智能诊断系统设计与实现

张三、李四、王五

示例大学计算机学院；南方科技大学计算机科学与工程系

2026 年 08 月 30 日

摘要：医学影像智能诊断是智慧医疗领域的核心研究方向。本文设计并实现了一套基于深度学习的医学影像智能诊断系统，涵盖数据预处理、模型训练、推理服务、可视化展示等完整流程。系统采用改进的 U-Net++ 架构进行病灶分割，结合 EfficientNet-B4 进行良恶性分类，在公开数据集 LUNA16 上达到了 92.3% 的分割准确率和 87.6% 的分类准确率。系统支持 DICOM 影像导入、多任务联合推理、Grad-CAM 可视化解释等功能，可辅助放射科医生进行高效诊断。实验结果表明，本系统在实际临床场景中具有较高的实用价值。

关键词：医学影像；深度学习；U-Net++；EfficientNet；智慧医疗

注：本文受国家自然科学基金（No. 12345678）与深圳市科技计划项目（No. JCYJ20240001）资助；中图分类号 TP391.4。

1 引言

医学影像是现代医疗诊断的重要依据。据统计，超过 70% 的临床诊断需要依赖医学影像 [1]。然而，传统的人工阅片方式存在以下痛点：

- 阅片工作量大，放射科医生严重不足
- 主观性强，不同医生之间一致性低
- 早期微小病灶容易漏诊

近年来，深度学习技术在医学影像分析领域取得了突破性进展 [2]。从肺结节检测到皮肤癌分类，从眼底病变识别到病理切片分析，AI 系统在多个任务上已达到甚至超越人类专家水平 [3]。

本文针对上述痛点，设计并实现了一套完整的医学影像智能诊断系统，主要贡献包括：

- 多任务联合模型：**同时支持病灶分割和良恶性分类两个任务
- 可解释性：**集成 Grad-CAM 热力图，辅助医生理解模型决策
- 工程化：**完整的 B/S 架构，支持 DICOM 标准和 RESTful API

2 相关工作

2.1 医学影像分割

U-Net [4] 是医学影像分割的经典架构，其编码-解码结构和跳跃连接在多个分割任务上取得优异性能。U-Net++ [5] 通过引入嵌套的跳跃连接进一步提升了分割精度。Attention U-Net [6] 则将注意力机制引入分割网络，自动聚焦于感兴趣区域。

2.2 医学影像分类

EfficientNet [7] 通过复合缩放策略在多个分类基准上取得 SOTA 性能。CheXNet [8] 在胸片疾病分类任务上达到了 F1 score 0.435，超过了人类放射科医生平均水平。

2.3 多任务学习

多任务学习通过共享特征表示提升泛化能力 [9]。在医学影像领域，分类与分割任务的联合学习能够显著提升模型性能 [10]。

3 系统设计

3.1 整体架构

系统采用前后端分离的 B/S 架构，整体架构如图 1 所示：浏览器端负责影像导入、可视化展示与报告生成；后端服务（FastAPI）承载影像管理、模型推理与用户认证；底层模型服务（Triton Inference Server）提供分割、分类与可解释性三类推理能力。




图 1：医学影像智能诊断系统整体架构

注：前后端通过 HTTPS 与 WebSocket 通信，后端与模型服务之间采用 gRPC 长连接以降低推理延迟。

3.2 数据流程

数据流程包含以下步骤：

1. 数据导入：支持 DICOM、NIFTI、PNG 等格式
2. 预处理：重采样、归一化、ROI 提取

3. 模型推理：调用分割和分类模型
4. 后处理：NMS、连通域分析、结果可视化
5. 报告生成：自动生成结构化诊断报告

4 模型设计

4.1 改进的 U-Net++

本文在标准 U-Net++ 基础上引入了两个改进：

- 深度监督：在多个解码层添加辅助损失
- 注意力门控：自动聚焦于病灶区域

公式 1 改进的 U-Net++ 损失函数： $L_{total} = \alpha L_{seg} + \beta L_{cls} + \gamma L_{aux}$

其中 L_{seg} 为主分割损失（Dice + BCE）， L_{cls} 为分类损失（Cross Entropy）， L_{aux} 为辅助损失。超参数 $\alpha = 1.0$ 、 $\beta = 0.5$ 、 $\gamma = 0.3$ 。

4.2 多任务联合训练

算法 1 多任务联合训练

“

```

1: 初始化网络参数  $\theta$ 
2: for epoch = 1 to E do
3: 随机打乱 D
4: for each batch (x, y_seg, y_cls) in D do
5: seg_pred, cls_pred, aux_preds  $\leftarrow$  forward(x,  $\theta$ )
6:  $L_{seg} \leftarrow$  DiceLoss(seg_pred, y_seg)
7:  $L_{cls} \leftarrow$  CrossEntropy(cls_pred, y_cls)
8:  $L_{aux} \leftarrow \sum_i \alpha_i \cdot \text{BCE}(\text{aux\_preds}[i], y_{seg})$ 
9:  $L \leftarrow L_{seg} + 0.5 \cdot L_{cls} + 0.3 \cdot L_{aux}$ 
10:  $\theta \leftarrow \theta - \eta \cdot \nabla L$ 
11: end for
12: if 验证集性能连续 5 轮不提升 then
13: break
14: end if
15: end for
16: return  $\theta$ 
输入：训练集 D，批次大小 B，学习率  $\eta$ ，总轮数 E
输出：训练好的模型参数

```

```

1: 初始化网络参数
2: for epoch = 1 to E do
3: 随机打乱 D
4: for each batch (x, y_seg, y_cls) in D do
5: seg_pred, cls_pred, aux_preds  $\leftarrow$  forward(x, )
6:  $L_{seg} \leftarrow$  DiceLoss(seg_pred, y_seg)
7:  $L_{cls} \leftarrow$  CrossEntropy(cls_pred, y_cls)
8:  $L_{aux} \leftarrow \sum_i \alpha_i \cdot \text{BCE}(\text{aux\_preds}[i], y_{seg})$ 
9:  $L \leftarrow L_{seg} + 0.5 \cdot L_{cls} + 0.3 \cdot L_{aux}$ 
10:  $\theta \leftarrow \theta - \eta \cdot \nabla L$ 
11: end for
12: if 验证集性能连续 5 轮不提升 then
13: break
14: end if
15: end for
16: return  $\theta$ 

```

4.3 模型参数

模型总参数量为 28.6M，FLOPs 为 5.7G，推理延迟（V100 GPU）< 50ms。

数据集	任务	样本数	模态
LUNA16	肺结节检测	888	CT
LIDC-IDRI	肺结节良恶性	1,018	CT
NIH ChestX-ray	胸片分类	112,120	X-ray
自有数据集	肝肿瘤分割	320	CT/MRI

5 实验与分析

5.1 数据集

5.2 评价指标

- 分割：Dice 系数、IoU、Hausdorff 距离
- 分类：Accuracy、Sensitivity、Specificity、AUC

5.3 实验结果

5.3.1 肺结节分割（LUNA16）

方法	Dice (%)	IoU (%)	推理时间 (ms)
U-Net	86.2	76.1	28
U-Net++	89.5	81.2	35
Attention U-Net	90.8	83.5	42
本文方法	92.3	85.7	48

5.3.2 肺结节良恶性分类

方法	Accuracy (%)	Sensitivity (%)	Specificity (%)	AUC
ResNet-50	81.4	79.2	83.5	0.871
EfficientNet-B4	84.7	82.6	86.5	0.901
本文方法	87.6	85.3	89.2	0.928

5.4 消融实验

6 系统实现

6.1 关键技术栈

```
1 # 后端核心代码示例
2 from fastapi import FastAPI, UploadFile, File
3 from pydantic import BaseModel
4 import torch
5 import numpy as np
6 from PIL import Image
7 import pydicom
8
9 app = FastAPI(title="Medical AI Service")
10
11 class DiagnosisResult(BaseModel):
```

改进	Dice (%)	Accuracy (%)
基线 (U-Net++)	89.5	84.7
+ 深度监督	90.8	86.1
+ 注意力门控	91.6	86.9
+ 多任务联合	92.3	87.6

```
12     segmentation_mask: bytes
13     cls_label: int
14     cls_confidence: float
15     gradcam_image: bytes
16
17 @app.post("/api/diagnose", response_model=DiagnosisResult)
18 async def diagnose(file: UploadFile = File(...)):
19     # 1. 读取 DICOM
20     if file.filename.endswith(".dcm"):
21         dcm = pydicom.dcmread(file.file)
22         image = dcm.pixel_array
23     else:
24         image = np.array(Image.open(file.file))
25
26     # 2. 预处理
27     tensor = preprocess(image).unsqueeze(0).to(device)
28
29     # 3. 模型推理
30     with torch.no_grad():
31         seg_pred, cls_pred, _ = model(tensor)
32
33     # 4. Grad-CAM
34     cam = generate_gradcam(model, tensor, target_class=cls_pred.argmax()
35 )
36
37     return DiagnosisResult(
38         segmentation_mask=seg_pred.cpu().numpy().tobytes(),
39         cls_label=cls_pred.argmax().item(),
40         cls_confidence=torch.softmax(cls_pred, dim=1).max().item(),
41         gradcam_image=cam.tobytes()
42     )
```

6.2 性能优化

- 模型量化：FP16 推理，吞吐量提升 2.3 倍
- 批处理：动态批合并，平均延迟降低 40%
- 缓存：高频影像特征缓存，重复请求响应 < 10ms

7 结论与展望

本文设计并实现了一套基于深度学习的医学影像智能诊断系统，涵盖数据管理、模型推理、可视化展示等完整流程。系统在公开数据集和真实临床场景中均取得了优异性能。

未来的研究方向包括：

1. 探索 Vision Transformer 在医学影像中的应用
2. 研究联邦学习支持跨医院协同训练（保护患者隐私）
3. 集成大语言模型实现自然语言报告生成

参考文献

- [1] Smith A, Jones B. The role of medical imaging in modern healthcare[J]. The Lancet, 2020, 395(10225): 678-685.
- [2] Litjens G, Kooi T, Bejnordi B E, et al. A survey on deep learning in medical image analysis[J]. Medical Image Analysis, 2017, 42: 60-88.
- [3] Esteva A, Chou K, Yeung S, et al. Deep learning-enabled medical computer vision[J]. NPJ Digital Medicine, 2021, 4(1): 1-9.
- [4] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional networks for biomedical image segmentation[C]. MICCAI, 2015: 234-241.
- [5] Zhou Z, Siddiquee M M R, Tajbakhsh N, et al. UNet++: A nested U-Net architecture for medical image segmentation[J]. IEEE TMI, 2019, 39(6): 1856-1867.
- [6] Oktay O, Schlemper J, Folgoc L L, et al. Attention U-Net: Learning where to look for the pancreas[C]. MIDL, 2018.
- [7] Tan M, Le Q. EfficientNet: Rethinking model scaling for convolutional neural networks[C]. ICML, 2019: 6105-6114.
- [8] Rajpurkar P, Irvin J, Zhu K, et al. CheXNet: Radiologist-level pneumonia detection on chest X-rays with deep learning[J]. arXiv:1711.05225, 2017.
- [9] Caruana R. Multitask learning[J]. Machine Learning, 1997, 28(1): 41-75.
- [10] Zhang Y, Yang Q. A survey on multi-task learning[J]. IEEE TKDE, 2021, 34(12): 5586-5609.