数理笔记

编著　作者姓名

单位名称

版权所有　侵权必究
© 2026

一、 基于深度学习的智慧交通流量预测系统设计报告

作者：王明计算机学院 2503010102 单位：示例大学日期：2026 年 8 月 29 日

二、 第一章绪论

2.1 1.1 研究背景与意义

随着城市化进程的加速，交通拥堵已成为深圳等大型城市面临的严峻挑战。传统的交通流量预测方法——如时间序列分析和统计回归——难以捕捉复杂的时空依赖关系，在面对突发状况时预测精度大幅下降。

基于深度学习的智慧交通预测系统，能够通过路网拓扑建模和时序演化分析，提供更准确的预测结果，从而辅助交通管理部门进行科学决策。

2.2 1.2 国内外研究现状

2.2.1 1.2.1 国外研究现状

国外学者较早开始研究交通流量预测问题。文献 [1] 提出基于 LSTM 的预测模型，在 METR-LA 数据集上取得良好效果。文献 [2] 进一步引入图卷积网络，建模路网空间结构。

2.2.2 1.2.2 国内研究现状

国内研究多聚焦于特定城市的实际场景。文献 [3] 针对北京市的交通特点提出了改进的 GRU 模型。文献 [4] 则研究了深圳的交通流特性，构建了融合多源数据的预测框架。

2.3 1.3 主要研究内容

本报告的主要研究内容包括：

1. **数据集构建**：采集深圳市福田区 6 个月的交通流量数据
2. **模型设计**：设计图卷积-时序混合网络架构
3. **系统实现**：开发完整的 B/S 架构 Web 系统
4. **部署验证**：在真实场景中验证系统有效性

2.4 1.4 报告组织结构

本报告共分六章：

- **第一章**绪论
- **第二章**相关技术与理论基础
- **第三章**需求分析与系统设计
- **第四章**模型设计与实现
- **第五章**系统测试与结果分析
- **第六章**总结与展望

三、 第二章相关技术与理论基础

3.1 2.1 深度学习基础

3.1.1 2.1.1 卷积神经网络（CNN）

卷积神经网络是处理网格结构数据（如图像）的经典架构。其核心思想是通过卷积核提取局部特征，再通过池化层降维。

3.1.2 2.1.2 循环神经网络（RNN）

循环神经网络擅长处理序列数据。LSTM 通过门控机制解决了传统 RNN 的梯度消失问题。

[] import torch import torch.nn as nn

class TrafficPredictor(nn.Module): def __init__(self, in_dim, hidden_dim, out_dim, num_layers=2): super().__init__() self.lstm = nn.LSTM(input_size=in_dim, hidden_size=hidden_dim, num_layers=num_layers, batch_first=True, dropout=0.2) self.fc = nn.Linear(hidden_dim, out_dim)

def forward(self, x): # x: (batch, seq_len, in_dim) lstm_out, _ = self.lstm(x) return self.fc(lstm_out[:, -1, :])

3.2 2.2 图神经网络

3.2.1 2.2.1 图卷积网络（GCN）

图卷积网络将传统卷积操作推广到图结构数据，能够有效建模节点间的拓扑关系。

公式 2.1 GCN 层的传播规则：

$$H^{(l+1)} = \sigma\left(\tilde{D}^{-1/2}\tilde{A}\tilde{D}^{-1/2}H^{(l)}W^{(l)}\right)$$

其中 $\tilde{A} = A + I$ 为加自环的邻接矩阵，$\tilde{D}$ 为对应的度矩阵。

3.2.2 2.2.2 图注意力网络（GAT）

GAT 通过注意力机制自适应地学习邻居节点的权重，进一步提升性能。

模型	MAE	RMSE	MAPE (%)
HA	6.02	9.78	17.50
LSTM	4.27	6.85	12.20
DCRNN	3.05	5.12	8.90
Graph WaveNet	2.69	4.65	7.60
本文模型	**2.31**	**3.98**	**6.45**

3.3 2.3 本章小结

本章系统梳理了深度学习与图神经网络的基础理论，为后续模型设计奠定了理论基础。

四、 第三章需求分析与系统设计

4.1 3.1 功能性需求

4.1.1 3.1.1 数据采集模块

- 支持实时接入路口摄像头数据
- 支持 CSV/JSON 批量导入
- 数据清洗与异常值处理

4.1.2 3.1.2 预测服务模块

- 支持未来 15/30/60 分钟多粒度预测
- 预测结果可视化展示
- 预测准确率实时监控

4.2 3.2 非功能性需求

- **性能**：单次预测响应时间 < 200ms
- **可用性**：系统 7×24 小时稳定运行
- **可扩展性**：支持横向扩展至 100+ 节点

4.3 3.3 系统架构设计

系统采用前后端分离的 B/S 架构：

浏览器（Vue + ECharts）

HTTPS / WebSocket

后端服务（FastAPI + Uvicorn）

模型推理　　数据管理　　用户认证

TCP / RPC

模型服务（PyTorch + TorchServe）

架构特点：前后端通过 RESTful API 解耦，模型服务可独立扩容，支持 GPU 集群推理。

五、 第四章模型设计与实现

5.1 4.1 数据预处理

5.1.1 4.1.1 数据集描述

本报告使用深圳市福田区 2024 年 1 月至 6 月的交通流量数据，包含：

- 156 个关键路口的实时车流量
- 5 分钟粒度采样，共约 50 万条记录
- 天气、节假日等外部特征

5.1.2 4.1.2 特征工程

- 时序特征：小时、星期、是否节假日
- 空间特征：路口邻接关系、路段长度
- 外部特征：天气、温度、特殊事件

5.2 4.2 模型架构

5.2.1 4.2.1 整体架构

模型由**空间建模**和**时序建模**两部分组成：

空间建模：使用 GAT 建模路口间的空间依赖关系

时序建模：使用 GRU 建模时序演化规律

融合层：拼接空间与时序特征，通过全连接层输出最终预测

5.2.2 4.2.2 损失函数

本报告使用 Masked MAE 损失，对缺失值不参与梯度计算：

公式 4.1 Masked MAE 损失：

$$L = \frac{\sum_i m_i \cdot |y_i - \hat{y}_i|}{\sum_i m_i + \epsilon}$$

其中 $m_i \in \{0, 1\}$ 为掩码标记，ϵ 为防止除零的小常数。

5.3 4.3 训练策略

- **优化器**：Adam（lr=1e-3, weight_decay=1e-5）
- **学习率调度**：ReduceLROnPlateau（factor=0.5, patience=5）
- **批量大小**：64
- **训练轮数**：100（early stopping，patience=10）

六、 第五章系统测试与结果分析

6.1 5.1 测试环境

6.2 5.2 性能测试

6.2.1 5.2.1 预测精度

6.2.2 5.2.2 系统响应时间

组件	配置
CPU	Intel Xeon Gold 6248 @ 2.5GHz × 2
GPU	NVIDIA Tesla V100 32GB
内存	128GB DDR4
操作系统	Ubuntu 20.04 LTS
深度学习框架	PyTorch 2.0 + CUDA 11.8

预测时长	MAE	RMSE	MAPE (%)
15 分钟	1.92	3.21	5.12
30 分钟	2.31	3.98	6.45
60 分钟	2.87	4.76	8.13

6.3 5.3 案例分析

以福田区深南大道-华富路口为例：

- **工作日早高峰**（8:00-9:00）：预测车流量 1,250 辆/小时，实际 1,287 辆/小时（误差 2.9%）
- **周末晚高峰**（18:00-19:00）：预测 980 辆/小时，实际 952 辆/小时（误差 2.9%）
- **特殊事件**（2024 年跨年夜）：预测 2,150 辆/小时，实际 2,398 辆/小时（误差 10.4%，仍优于基线）

七、 第六章总结与展望

7.1 6.1 工作总结

本报告完成的主要工作包括：

1. 系统梳理了智慧交通预测领域的国内外研究现状
2. 构建了基于图卷积-时序网络的混合预测模型
3. 设计并实现了完整的 B/S 架构 Web 预测系统
4. 在深圳市福田区真实场景中验证了系统有效性

7.2 6.2 主要创新点

- **多尺度时空融合**：同时建模短期突变与长期趋势
- **外部特征自适应融合**：自动学习天气、节假日等外部因素的影响
- **边缘-云端协同部署**：在保证精度的同时提升响应速度

并发数	平均响应 (ms)	P99 响应 (ms)
10	45	89
50	78	156
100	124	245
200	198	387

7.3 6.3 不足与展望

本系统仍存在以下不足：

1. 模型可解释性有待加强
2. 极端天气下的预测精度需进一步提升
3. 暂未支持跨城市迁移

未来将探索：

- 引入因果推断提升可解释性
- 研究联邦学习支持跨城市协同训练
- 集成大语言模型实现自然语言交互式查询

7.4 参考文献

[1] Li Y, Yu R, Shahabi C, et al. Diffusion convolutional recurrent neural network: Data-driven traffic forecasting[C]. ICLR, 2018.

[2] Zhao L, Song Y, Zhang C, et al. T-GCN: A temporal graph convolutional network for traffic prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 21(9): 3848-3858.

[3] 王伟, 李强. 基于改进 GRU 的城市交通流量预测方法 [J]. 计算机应用研究, 2022, 39(5): 1452-1456.

[4] 陈晓, 刘洋. 融合多源数据的深圳交通流预测研究 [J]. 智能系统学报, 2023, 18(3): 567-575.