

基于深度学习的智慧交通流量预测系统设计报告

王明计算机学院 2503010102

示例大学

2026 年 08 月 30 日

目 录

第一章绪论	3
1.1 研究背景与意义	3
1.2 国内外研究现状	3
1.2.1 国外研究现状	3
1.2.2 国内研究现状	3
1.3 主要研究内容	3
1.4 报告组织结构	3
第二章相关技术与理论基础	5
2.1 深度学习基础	5
2.1.1 卷积神经网络（CNN）	5
2.1.2 循环神经网络（RNN）	5
2.2 图神经网络	5
2.2.1 图卷积网络（GCN）	6
2.2.2 图注意力网络（GAT）	6
2.3 本章小结	6
第三章需求分析与系统设计	7
3.1 功能性需求	7
3.1.1 数据采集模块	7
3.1.2 预测服务模块	7
3.2 非功能性需求	7
3.3 系统架构设计	7
第四章模型设计与实现	9
4.1 数据预处理	9
4.1.1 数据集描述	9
4.1.2 特征工程	9
4.2 模型架构	9
4.2.1 整体架构	9
4.2.2 损失函数	9
4.3 训练策略	9

第五章系统测试与结果分析	11
5.1 测试环境	11
5.2 性能测试	11
5.2.1 预测精度	11
5.2.2 系统响应时间.....	11
5.3 案例分析	11
第六章总结与展望	13
6.1 工作总结	13
6.2 主要创新点	13
6.3 不足与展望.....	13

第一章绪论

1.1 研究背景与意义

随着城市化进程的加速，交通拥堵已成为深圳等大城市面临的严峻挑战。传统的交通流量预测方法——如时间序列分析和统计回归——难以捕捉复杂的时空依赖关系，在面对突发状况时预测精度大幅下降。

基于深度学习的智慧交通预测系统，能够通过路网拓扑建模和时序演化分析，提供更准确的预测结果，从而辅助交通管理部门进行科学决策。

1.2 国内外研究现状

1.2.1 国外研究现状

国外学者较早开始研究交通流量预测问题。文献 [1] 提出基于 LSTM 的预测模型，在 METR-LA 数据集上取得良好效果。文献 [2] 进一步引入图卷积网络，建模路网空间结构。

1.2.2 国内研究现状

国内研究多聚焦于特定城市的实际场景。文献 [3] 针对北京市的交通特点提出了改进的 GRU 模型。文献 [4] 则研究了深圳的交通流特性，构建了融合多源数据的预测框架。

1.3 主要研究内容

本报告的主要研究内容包括：

- 数据集构建：**采集深圳市福田区 6 个月的交通流量数据
- 模型设计：**设计图卷积-时序混合网络架构
- 系统实现：**开发完整的 B/S 架构 Web 系统
- 部署验证：**在真实场景中验证系统有效性

1.4 报告组织结构

本报告共分六章：

- 第一章绪论

- 第二章相关技术与理论基础
 - 第三章需求分析与系统设计
 - 第四章模型设计与实现
 - 第五章系统测试与结果分析
 - 第六章总结与展望
-

第二章相关技术与理论基础

2.1 深度学习基础

2.1.1 卷积神经网络 (CNN)

卷积神经网络是处理网格结构数据（如图像）的经典架构。其核心思想是通过卷积核提取局部特征，再通过池化层降维。

2.1.2 循环神经网络 (RNN)

循环神经网络擅长处理序列数据。LSTM 通过门控机制解决了传统 RNN 的梯度消失问题。

```
1 import torch
2 import torch.nn as nn
3
4 class TrafficPredictor(nn.Module):
5     def __init__(self, in_dim, hidden_dim, out_dim, num_layers=2)
6         :
7         super().__init__()
8         self.lstm = nn.LSTM(
9             input_size=in_dim,
10             hidden_size=hidden_dim,
11             num_layers=num_layers,
12             batch_first=True,
13             dropout=0.2
14         )
15         self.fc = nn.Linear(hidden_dim, out_dim)
16
17     def forward(self, x):
18         # x: (batch, seq_len, in_dim)
19         lstm_out, _ = self.lstm(x)
20         return self.fc(lstm_out[:, -1, :])
```

2.2 图神经网络

2.2.1 图卷积网络（GCN）

图卷积网络将传统卷积操作推广到图结构数据，能够有效建模节点间的拓扑关系。

公式 2.1 GCN 层的传播规则： $H^{(l+1)} = \sigma \left(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(l)} W^{(l)} \right)$

其中 $\tilde{A} = A + I$ 为加自环的邻接矩阵， $\tilde{D}$ 为对应的度矩阵。

2.2.2 图注意力网络（GAT）

GAT 通过注意力机制自适应地学习邻居节点的权重，进一步提升性能。

模型	MAE	RMSE	MAPE (%)
HA	6.02	9.78	17.50
LSTM	4.27	6.85	12.20
DCRNN	3.05	5.12	8.90
Graph WaveNet	2.69	4.65	7.60
本文模型	2.31	3.98	6.45

2.3 本章小结

本章系统梳理了深度学习与图神经网络的基础理论，为后续模型设计奠定了理论基础。

—

第三章需求分析与系统设计

3.1 功能性需求

3.1.1 数据采集模块

- 支持实时接入路口摄像头数据
- 支持 CSV/JSON 批量导入
- 数据清洗与异常值处理

3.1.2 预测服务模块

- 支持未来 15/30/60 分钟多粒度预测
- 预测结果可视化展示
- 预测准确率实时监控

3.2 非功能性需求

- 性能：单次预测响应时间 < 200ms
- 可用性：系统 7×24 小时稳定运行
- 可扩展性：支持横向扩展至 100+ 节点

3.3 系统架构设计

系统采用前后端分离的 B/S 架构：



12
13
14

模型服务（PyTorch + TorchServe）

架构特点：前后端通过 RESTful API 解耦，模型服务可独立扩容，支持 GPU 集群推理。

第四章模型设计与实现

4.1 数据预处理

4.1.1 数据集描述

本报告使用深圳市福田区 2024 年 1 月至 6 月的交通流量数据，包含：

- 156 个关键路口的实时车流量
- 5 分钟粒度采样，共约 50 万条记录
- 天气、节假日等外部特征

4.1.2 特征工程

- 时序特征：小时、星期、是否节假日
- 空间特征：路口邻接关系、路段长度
- 外部特征：天气、温度、特殊事件

4.2 模型架构

4.2.1 整体架构

模型由空间建模和时序建模两部分组成：

空间建模：使用 GAT 建模路口间的空间依赖关系

时序建模：使用 GRU 建模时序演化规律

融合层：拼接空间与时序特征，通过全连接层输出最终预测

4.2.2 损失函数

本报告使用 Masked MAE 损失，对缺失值不参与梯度计算：

$$\text{公式 4.1 Masked MAE 损失: } \$L = \frac{\sum_i m_i \cdot |y_i - \hat{y}_i|}{\sum_i m_i + \epsilon} \$$$

其中 $m_i \in \{0, 1\}$ 为掩码标记， ϵ 为防止除零的小常数。

4.3 训练策略

- 优化器：Adam (lr=1e-3, weight_decay=1e-5)

- 学习率调度: ReduceLROnPlateau (factor=0.5, patience=5)
 - 批量大小: 64
 - 训练轮数: 100 (early stopping, patience=10)
-

第五章系统测试与结果分析

5.1 测试环境

组件	配置
CPU	Intel Xeon Gold 6248 @ 2.5GHz × 2
GPU	NVIDIA Tesla V100 32GB
内存	128GB DDR4
操作系统	Ubuntu 20.04 LTS
深度学习框架	PyTorch 2.0 + CUDA 11.8

5.2 性能测试

5.2.1 预测精度

预测时长	MAE	RMSE	MAPE (%)
15 分钟	1.92	3.21	5.12
30 分钟	2.31	3.98	6.45
60 分钟	2.87	4.76	8.13

5.2.2 系统响应时间

并发数	平均响应 (ms)	P99 响应 (ms)
10	45	89
50	78	156
100	124	245
200	198	387

5.3 案例分析

以福田区深南大道-华富路口为例：

- 工作日早高峰（8:00-9:00）：预测车流量 1,250 辆/小时，实际 1,287 辆/小时（误差 2.9%）

- **周末晚高峰** (18:00-19:00)：预测 980 辆/小时，实际 952 辆/小时 (误差 2.9%)
 - **特殊事件** (2024 年跨年夜)：预测 2,150 辆/小时，实际 2,398 辆/小时 (误差 10.4%，仍优于基线)
-

第六章总结与展望

6.1 工作总结

本报告完成的主要工作包括：

- 系统梳理了智慧交通预测领域的国内外研究现状
- 构建了基于图卷积-时序网络的混合预测模型
- 设计并实现了完整的 B/S 架构 Web 预测系统
- 在深圳市福田区真实场景中验证了系统有效性

6.2 主要创新点

- 多尺度时空融合：同时建模短期突变与长期趋势
- 外部特征自适应融合：自动学习天气、节假日等外部因素的影响
- 边缘-云端协同部署：在保证精度的同时提升响应速度

6.3 不足与展望

本系统仍存在以下不足：

- 模型可解释性有待加强
- 极端天气下的预测精度需进一步提升
- 暂未支持跨城市迁移

未来将探索：

- 引入因果推断提升可解释性
 - 研究联邦学习支持跨城市协同训练
 - 集成大语言模型实现自然语言交互式查询
-

参考文献

- [1] Li Y, Yu R, Shahabi C, et al. Diffusion convolutional recurrent neural network: Data-driven traffic forecasting[C]. ICLR, 2018.
- [2] Zhao L, Song Y, Zhang C, et al. T-GCN: A temporal graph convolutional network for traffic prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2019, 21(9): 3848-3858.
- [3] 王伟, 李强. 基于改进 GRU 的城市交通流量预测方法 [J]. 计算机应用研究, 2022, 39(5): 1452-1456.
- [4] 陈晓, 刘洋. 融合多源数据的深圳交通流预测研究 [J]. 智能系统学报, 2023, 18(3): 567-575.