

▶ 用户输入消息

1. 意图分类 1~5ms

意图



3. 难度调整 < 1ms

难度



4. 上下文构建

5. 系统提示组装

6. 流式响应

▼ 异步后处理

■ 返回完整响应