

基于注意力机制的轻量化图像分类方法研究

张三¹ 李四² 王五¹

¹ 计算机学院, 深圳 518172

² 南方科技大学计算机科学与工程系, 深圳 518055

摘要: 图像分类是计算机视觉领域的基础任务之一。近年来, 深度学习技术的快速发展为图像分类带来了革命性的突破。然而, 高性能模型通常伴随着巨大的参数量和计算成本, 难以部署到资源受限的边缘设备。本文提出了一种基于注意力机制的轻量化图像分类方法, 在保持较高准确率的同时显著降低了模型复杂度。实验结果表明, 所提方法在 ImageNet 数据集上的 Top-1 准确率达到 78.3%, 参数量仅为 3.2M, FLOPs 为 0.8G, 优于现有的 MobileNetV3 和 ShuffleNetV2 等轻量化模型。本文还对注意力机制的作用原理进行了深入分析, 并通过消融实验验证了各模块的有效性。

关键词: 图像分类; 注意力机制; 轻量化网络; 深度学习

1 引言

图像分类是计算机视觉中最基本的任务之一, 其目标是将输入图像分配到预定义的类别中 [1]。传统方法依赖手工设计的特征提取器, 泛化能力有限。深度学习技术的兴起——特别是卷积神经网络 (CNN) ——彻底改变了这一局面。

自 AlexNet[2] 在 2012 年 ImageNet 挑战赛中取得突破以来, 研究者们提出了大量 CNN 架构。ResNet[4] 通过残差连接解决了深层网络训练困难的问题, EfficientNet[8] 则通过复合缩放策略实现了效率与精度的平衡。

然而, 这些高性能模型往往包含数百万甚至数千万参数, 难以在移动设备、嵌入式系统等资源受限场景中部署。为此, 研究者们提出了多种轻量化设计策略。

本文的主要贡献如下:

- 提出了一种融合通道注意力和空间注意力的轻量化模块, 在保持低计算量的同时有效增强了特征表达
- 设计了渐进式通道压缩策略, 逐步减少特征通道数, 显著降低参数量
- 在 ImageNet 和 CIFAR-100 数据集上进行了充分的实验验证

2 相关工作

2.1 轻量化卷积神经网络

轻量化网络设计是当前的研究热点之一。MobileNet 系列 [6] 使用深度可分离卷积替代标准卷积, 将计算量降低约 8-9 倍。ShuffleNet[7] 引入通道混洗操作, 在分组卷积后增强通道间的信息流动。EfficientNet[8] 提出了复合缩放策略。

2.2 注意力机制

注意力机制最早在自然语言处理领域取得了巨大成功，随后被引入计算机视觉领域。SE-Net 通过全局平均池化和全连接层学习通道间的依赖关系。CBAM 同时使用通道注意力和空间注意力来增强特征表示。

(通道注意力) 通道注意力关注“什么”是有意义的特征通道，通过全局池化聚合空间信息后学习通道维度的权重。

(空间注意力) 空间注意力关注“哪里”是关键区域，通过通道维度的池化后学习空间位置的权重分布。

3 本文方法

3.1 整体架构

本文提出的轻量化网络架构如图1所示。网络由三个主要阶段组成：初始特征提取阶段、深度特征学习阶段和分类预测阶段。



图 1: 本文提出的轻量化图像分类网络架构

3.2 轻量化注意力模块

本文设计的轻量化注意力模块（LAM）同时融合了通道注意力和空间注意力，其结构如算法1所示。

(通道注意力分支) 通道注意力分支首先通过全局平均池化将空间信息压缩为一个向量，然后使用一维卷积在相邻通道间进行信息交互，最后使用 Sigmoid 函数生成通道权重。

(空间注意力分支) 空间注意力分支在通道维度上分别计算均值和最大值，拼接后使用大卷积核（ 7×7 ）捕获空间上下文信息，生成空间注意力图。

3.3 渐进式通道压缩

传统轻量化网络通常在不同阶段使用固定的通道数配置。本文提出了渐进式通道压缩策略，在网络深层逐步减少通道数，同时保持足够的特征维度。

算法 1: 轻量化注意力模块前向传播

输入: 输入特征图 $X \in \mathbb{R}^{C \times H \times W}$
 输出: 增强后的特征图 $Y \in \mathbb{R}^{C \times H \times W}$

- 1 $g_c \leftarrow \text{GAP}(X)$ // 全局平均池化 $\rightarrow C \times 1 \times 1$
- 2 $g_c \leftarrow \text{Conv1d}_{k=3}(\text{ReLU}(\text{Conv1d}_{k=3}(g_c)))$ // 一维卷积通道交互
- 3 $A_c \leftarrow \sigma(g_c)$ // Sigmoid 激活
- 4 $X_c \leftarrow A_c \odot X$ // 通道维加权
- 5 $g_s \leftarrow \text{Mean}(X_c, \text{dim} = 1)$ // 通道维取均值 $\rightarrow 1 \times H \times W$
- 6 $g_s \leftarrow \text{Conv}_{7 \times 7}([g_s; \text{Max}(X_c, \text{dim} = 1)])$ // 拼接均值与最大值
- 7 $A_s \leftarrow \sigma(g_s)$ // Sigmoid 激活
- 8 $Y \leftarrow A_s \odot X_c$ // 空间维加权
- 9 **return** Y

设第 i 个阶段的输出通道数为 C_i , 则:

$$C_i = C_0 \cdot \alpha^i \quad (i = 1, 2, \dots, N) \quad (3.1)$$

其中 C_0 为基础通道数, $\alpha \in (0, 1]$ 为压缩因子, N 为阶段总数。本文中取 $C_0 = 64$, $\alpha = 0.75$ 。

4 实验结果

4.1 实验设置

所有实验在 PyTorch 框架下完成, 使用 NVIDIA RTX 3090 GPU 训练。优化器为 SGD with momentum, 初始学习率 0.1, cosine 衰减策略, batch size 为 256, 共训练 300 个 epoch。

4.2 ImageNet 分类结果

表1展示了本文方法与主流轻量化模型在 ImageNet 数据集上的性能对比。

方法	参数量 (M)	FLOPs(G)	Top-1(%)	Top-5(%)
MobileNetV2	3.5	0.30	72.0	91.0
MobileNetV3-Large	5.4	0.22	75.2	92.2
ShuffleNetV2	2.3	0.15	72.6	90.6
EfficientNet-B0	5.3	0.39	77.1	93.3
GhostNet	5.2	0.14	73.9	91.4
本文方法	3.2	0.18	78.3	94.0

表 1: ImageNet 数据集上的性能对比

从表1可以看出, 本文方法以 3.2M 的参数数量和 0.18G 的 FLOPs, 取得了 78.3% 的 Top-1 准确率, 在精度和效率之间达到了最优平衡。

4.3 消融实验

表2展示了各模块的消融实验结果。

注: LAM 为轻量化注意力模块, PCC 为渐进式通道压缩策略。实验结果表明, 两种策略均

Baseline	LAM	PCC	Params(M)	Top-1(%)
✓			3.0	76.1
✓	✓		3.4	77.5
✓		✓	2.8	76.8
✓	✓	✓	3.2	78.3

表 2: 消融实验结果

可独立提升模型性能，且具有协同效应。

5 结论

本文提出了一种基于注意力机制的轻量化图像分类方法。通过在 MobileNetV3 的基础上引入融合通道和空间注意力的轻量化模块，并辅以渐进式通道压缩策略，在保持低计算量的同时显著提升了分类精度。未来的工作将探索将该方法扩展到目标检测和语义分割等下游任务。

基金项目：国家自然科学基金（No. 12345678）；深圳市科技计划项目（No. JCYJ20240001）

参考文献

- [1] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.
- [2] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]. NeurIPS, 2012.
- [3] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv:1409.1556, 2014.
- [4] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. CVPR, 2016.
- [5] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]. CVPR, 2017.
- [6] Howard A G, Zhu M, Chen B, et al. MobileNets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv:1704.04861, 2017.
- [7] Zhang X, Zhou X, Lin M, et al. ShuffleNet: An extremely efficient convolutional neural network for mobile devices[C]. CVPR, 2018.
- [8] Tan M, Le Q V. EfficientNet: Rethinking model scaling for convolutional neural networks[C]. ICML, 2019.

作者简介：

张三（1990-），男，博士，副教授，主要研究方向为计算机视觉、深度学习。E-mail: zhangsan@harryopo.edu.cn