

基于注意力机制的轻量化图像分类方法研究

张三 计算机学院 2025000101

示例大学

2026 年 09 月 18 日

摘要：图像分类是计算机视觉领域的基础任务之一。本文提出了一种基于注意力机制的轻量化图像分类方法，在保持较高准确率的同时显著降低了模型复杂度。实验结果表明，所提方法在 ImageNet 数据集上的 Top-1 准确率达到 78.3%，参数量仅为 3.2M，FLOPs 为 0.8G，优于现有的 MobileNetV3 和 ShuffleNetV2 等轻量化模型。

关键词：图像分类；注意力机制；轻量化网络；深度学习

一、引言

图像分类是计算机视觉中最基本的任务之一，其目标是将输入图像分配到预定义的类别中。传统方法依赖手工设计的特征提取器，泛化能力有限。深度学习技术的兴起——特别是卷积神经网络（CNN）——彻底改变了这一局面。

自 AlexNet 在 2012 年 ImageNet 挑战赛中取得突破以来，研究者们提出了大量 CNN 架构。ResNet 通过残差连接解决了深层网络训练困难的问题，EfficientNet 则通过复合缩放策略实现了效率与精度的平衡。

1.1 研究背景

随着移动设备和边缘计算的普及，模型轻量化成为研究热点。轻量化模型需要在保持较高准确率的同时，显著减少参数量和计算量。

1.2 主要贡献

本文的主要贡献包括：

- 提出了一种新的通道注意力机制，计算开销降低 40%
- 设计了自适应空间池化模块，增强多尺度特征提取能力
- 在 ImageNet、CIFAR-100 上均取得 SOTA 性能

二、相关工作

2.1 轻量化网络

MobileNetV3 通过深度可分离卷积和 SE 注意力机制实现高效推理；ShuffleNetV2 则通过通道混洗优化并行计算。

模型	Top-1 (%)	Params (M)	FLOPs (G)
MobileNetV3-Small	67.5	2.5	0.06
ShuffleNetV2-1.0×	69.4	2.3	0.15
EfficientNet-B0	77.3	5.3	0.39
本文方法	78.3	3.2	0.8


2.2 注意力机制

SE 注意力通过全局平均池化建模通道关系，CBAM 进一步引入空间注意力。两者均能以较小开销提升模型性能。

三、方法

3.1 整体架构

本文方法的整体架构如下图所示：



3.2 轻量化注意力模块

轻量化注意力模块（LAM）由两个分支组成：通道注意力分支和空间注意力分支。

公式 1 通道注意力计算公式： $M_c(F) = \sigma(\text{MLP}(\text{AvgPool}(F)) + \text{MLP}(\text{MaxPool}(F)))$

其中 σ 表示 Sigmoid 激活函数，MLP 为多层感知机。

```
1 class LightweightAttention(nn.Module):
2     def __init__(self, channels, reduction=16):
3         super().__init__()
4         self.avg_pool = nn.AdaptiveAvgPool2d(1)
5         self.max_pool = nn.AdaptiveMaxPool2d(1)
6         self.mlp = nn.Sequential(
7             nn.Linear(channels, channels // reduction),
8             nn.ReLU(inplace=True),
9             nn.Linear(channels // reduction, channels),
10            nn.Sigmoid()
11        )
12
13    def forward(self, x):
14        b, c, _, _ = x.size()
15        avg_out = self.mlp(self.avg_pool(x).view(b, c))
16        max_out = self.mlp(self.max_pool(x).view(b, c))
17        scale = (avg_out + max_out).view(b, c, 1, 1)
18        return x * scale.expand_as(x)
```

3.3 损失函数

本文使用标签平滑交叉熵损失：

公式 2 标签平滑交叉熵损失：
$$L = - \sum_{i=1}^C y_i^{\text{smooth}} \log(p_i), \quad y_i^{\text{smooth}} = (1 - \epsilon)y_i + \frac{\epsilon}{C}$$

其中 $\epsilon = 0.1$ 为平滑系数， C 为类别数。

四、实验与分析

4.1 实验设置

- 数据集：ImageNet-1K（1000 类，128 万张训练图像）
- 优化器：SGD（momentum=0.9, weight_decay=4e-5）
- 初始学习率：0.1，cosine 衰减，训练 300 epoch
- 批量大小：256（4×RTX 3090）

4.2 消融实验

模块	Top-1 (%)	Params (M)	FLOPs (G)
基线	72.4	2.8	0.5
+ 通道注意力	76.1	3.0	0.7
+ 空间注意力	77.5	3.1	0.75
+ 标签平滑	78.3	3.2	0.8

结论：三个模块均带来稳定提升，组合使用时效果最佳。

4.3 可视化分析

通过 Grad-CAM 可视化发现，注意力模块能有效聚焦于图像的判别性区域，抑制背景噪声的干扰。

五、结论

本文提出了一种基于注意力机制的轻量化图像分类方法，通过通道-空间双分支注意力设计，在仅增加 14% 参数量的前提下将 Top-1 准确率从 72.4% 提升至 78.3%。实验结果表明所提方法在精度和效率间取得了良好平衡，适合在边缘设备上部署。

未来的研究方向包括：

- 探索神经架构搜索（NAS）自动设计注意力模块
- 研究量化感知训练，进一步压缩模型体积
- 拓展到目标检测、语义分割等下游任务

参考文献

- [1] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]. NeurIPS, 2012: 1097-1105.
- [2] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. CVPR, 2016: 770-778.
- [3] Tan M, Le Q. EfficientNet: Rethinking model scaling for convolutional neural networks[C]. ICML, 2019: 6105-6114.
- [4] Howard A, Sandler M, Chu G, et al. Searching for MobileNetV3[C]. ICCV, 2019: 1314-1324.
- [5] Ma N, Zhang X, Zheng H T, et al. ShuffleNetV2: Practical guidelines for efficient CNN architecture design[C]. ECCV, 2018: 116-131.