

基

PAPER

基于检索增强生成的多模态智能问答系统设计与实现

Design and Implementation of a Multimodal Intelligent QA System
Based on Retrieval-Augmented Generation

8

章节数

Sections

48

内容块

Blocks

作者	张小明
班级	计算机科学与技术 2201 班
学校	示例大学
版本	v1.0.0 · 2026-08-04
主题	石墨冷峻 (Slate Dark)

目录

Table of Contents · 8 个章节

一、摘要

二、引言

三、相关工作

四、系统架构

五、核心方法

六、实验与结果

七、结论

八、参考文献

摘要

第一章 基于检索增强生成的多模态智能问答系统设计与实现 · 石墨冷峻主题

随着大语言模型（Large Language Model, LLM）的快速发展，检索增强生成（Retrieval-Augmented Generation, RAG）已成为缓解模型幻觉、引入外部知识的关键范式。本文设计并实现了一个多模态智能问答系统，系统采用"向量检索 + 重排序 + 生成"的三级流水线，对文本、表格与图片进行统一嵌入与检索。核心创新包括：基于动态温度系数 τ 的检索概率校准，以及融合跨模态注意力权重的答案生成策略。在领域问答数据集上的实验表明，所提方法将答案准确率从基线 RAG 的 78.3% 提升至 91.6%，并将平均检索延迟控制在 320 ms 以内，验证了系统的有效性与实用性。

引言

第一章 · 共 8 章

检索增强生成通过先从外部知识库检索相关文档片段，再将其与用户问题拼接后交由生成模型作答，从而在不重新训练的前提下注入领域知识。设用户问题为 q ，检索器返回 N 个候选文档片段 $\mathcal{D} = \{d_1, d_2, \dots, d_N\}$ ，生成模型的目标是最大化条件概率

$$P(a \mid q, \mathcal{D}) = \prod_{t=1}^T P_{\theta}(a_t \mid a_{<t}, q, \mathcal{D})$$

其中 $a = (a_1, \dots, a_T)$ 为生成的答案序列。然而，传统 RAG 存在三个关键问题：

- 检索质量不足：单一向量相似度难以度量复杂语义
- 知识时效性弱：静态索引无法应对增量数据
- 多模态支持缺失：现有方案难以统一处理图文混合内容

本文针对上述问题，提出一种多模态智能问答系统，主要贡献如下：

- 设计"向量检索 + 重排序 + 生成"三级流水线架构
- 提出动态温度系数的检索概率校准方法
- 构建统一多模态嵌入空间，支持文本、表格与图片的联合检索

相关工作

2.1 向量检索

稠密检索模型将文本映射到高维向量空间，并通过相似度函数度量相关性。最常用的相似度度量是余弦相似度（Cosine Similarity）：

$$\text{sim}(\mathbf{q}, \mathbf{d}) = \frac{\mathbf{q} \cdot \mathbf{d}}{\|\mathbf{q}\| \cdot \|\mathbf{d}\|} = \frac{\sum_{i=1}^m q_i d_i}{\sqrt{\sum_{i=1}^m q_i^2} \cdot \sqrt{\sum_{i=1}^m d_i^2}}$$

其中 $\mathbf{q} \in \mathbb{R}^m$ 为查询向量， $\mathbf{d} \in \mathbb{R}^m$ 为文档向量。该度量对向量模长不敏感，适合高维稀疏场景。

2.2 检索增强生成

Lewis 等人（2020）首次系统提出 RAG 框架，将预训练的参数化记忆（Parametric Memory）与非参数化记忆（Non-parametric Memory）相结合。给定查询 q ，检索器依据概率分布 $p_\eta(d | q)$ 采样文档，生成器 $p_\theta(a | q, d)$ 基于采样文档生成答案，最终目标函数为

$$\mathcal{L}_{\text{RAG}} = \sum_{(q,a)} \log \sum_{d \in \mathcal{D}} p_\eta(d | q) \cdot p_\theta(a | q, d)$$

三 · SECTION

系统架构

系统采用分层架构设计，共分为三层，各层职责明确、通过标准化接口解耦：



其中服务层的 RAG 引擎内部又划分为四个子模块，其处理流水线如图 2 所示：

RAG 引擎内部流水线

检索模块

基于检索增强生成的多模态智能问答系统设计与实现 · 石墨冷峻主题

查询改写

混合检索

候选召回

重排模块

语义重排

阈值过滤

Top-K 截断

生成模块

Prompt 组装

多模态生成

答案校验

优化模块

反馈采集

增量索引

效果评估

3.1 查询处理

用户查询首先经过预处理管道，包括分词、停用词过滤与查询改写。改写阶段采用轻量级生成模型对原始查询 q 进行扩展，生成查询变体集合 $\{q, q_1, q_2, \dots, q_K\}$ ，其中每个变体捕获不同的查询意图，最终检索得分取变体得分的加权融合

$$\text{Score}(d) = \sum_{k=1}^K w_k \cdot \text{sim}(\mathbf{q}_k, \mathbf{d}), \quad \sum_{k=1}^K w_k = 1$$

四 · SECTION

核心方法

第四章 · 共 8 章

4.1 检索概率校准

传统 RAG 直接使用向量相似度排序，分数尺度在不同查询间差异巨大。本文引入温度系数 τ 对检索分数进行软最大化（Softmax）校准，将相似度转化为检索概率：

$$P(d_k | q) = \frac{\exp(\text{sim}(\mathbf{q}, \mathbf{d}_k) / \tau)}{\sum_{j=1}^K \exp(\text{sim}(\mathbf{q}, \mathbf{d}_j) / \tau)}$$

温度系数 τ 控制概率分布的锐度： $\tau \rightarrow 0$ 时退化为硬选择， $\tau \rightarrow \infty$ 时趋于均匀分布。本文提出动态温度策略，根据查询置信度 $c(q)$ 自适应调节：

$$\tau(q) = \tau_{\min} + (\tau_{\max} - \tau_{\min}) \cdot \frac{1}{1 + e^{\alpha(c(q) - c_0)}}$$

4.2 多模态嵌入融合

对于图文混合内容，本文采用跨模态注意力机制融合文本与视觉特征。设文本特征矩阵 $\mathbf{T} \in \mathbb{R}^{m \times d_t}$ ，视觉特征矩阵 $\mathbf{V} \in \mathbb{R}^{n \times d_v}$ ，先通过线性投影对齐到同一维度 d ，再计算注意力：

$$\text{Attn}(\mathbf{T}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{T} \mathbf{W}_Q (\mathbf{V} \mathbf{W}_K)^\top}{\sqrt{d}} \right) \mathbf{V} \mathbf{W}_V$$

融合后的表示 $\mathbf{h} = \text{Attn}(\mathbf{T}, \mathbf{V})$ 与文本语义向量拼接，构成最终检索向量。

4.3 答案生成与评估

生成阶段采用 Top- k 截断采样，并引入长度惩罚系数 β 。解码器在每一步计算词汇分布：

$$P(w_t | w_{<t}) = \frac{\exp(z_{w_t} / T_g)}{\sum_{w \in \mathcal{V}} \exp(z_w / T_g)}$$

其中 $\mathcal{V}$ 为词表， z_w 为对数几率， T_g 为生成温度。系统评估采用如下指标：答案准确率（Accuracy）、F1 分数与生成困惑度（Perplexity）

$$\text{PPL} = \exp \left(-\frac{1}{N} \sum_{i=1}^N \log P_\theta(w_i | w_{<i}) \right)$$

$$\text{F1} = \frac{2 \cdot P \cdot R}{P + R}$$

其中 P 为精确率， R 为召回率。

五 · SECTION

实验与结果

第五章 · 共 8 章

5.1 实验设置

实验基于领域问答数据集构建，共 12,000 条问答对，按 8:1:1 划分为训练集、验证集与测试集。基线系统包括：BM25 稀疏检索、传统 RAG（仅向量检索）、本文方法（校准 + 多模态融合）。

基于检索增强生成的多模态智能问答系统设计与实现 · 石墨冷峻主题

5.2 主实验结果

方法	准确率 (%)	F1 (%)	平均延迟 (ms)	索引大小 (MB)
BM25 稀疏检索	61.2	55.8	42	18
传统 RAG（向量）	78.3	74.6	287	156
RAG + 重排序	85.4	82.1	305	156
本文方法（完整）	91.6	89.3	320	162

实验结论

在引入动态温度校准与多模态融合后，系统准确率相对传统 RAG 提升 13.3 个百分点，同时平均延迟仅增加 33 ms，处于可接受范围。

5.3 消融实验

为验证各模块贡献，本文进行了消融实验：

配置	准确率 (%)	F1 (%)
完整系统	91.6	89.3
- 动态温度校准	88.9	86.4
- 多模态融合	86.2	83.8
- 重排序模块	82.7	80.1

结果显示动态温度校准贡献约 2.7 个百分点，多模态融合贡献约 2.7 个百分点，重排序贡献约 3.5 个百分点，各模块均发挥显著作用。

六 · SECTION

结论

第六章 · 共 8 章

本文设计并实现了一个基于检索增强生成的多模态智能问答系统。系统通过三级流水线架构、动态温度概率校准与跨模态注意力融合，显著提升了领域问答的准确率与鲁棒性。实验表明，所提方法在准确率与 F1 指标上均优于基线系统。未来工作将聚焦于流式增量索引更新与个性化知识偏好建模。

参考文献

第八章 基于检索增强生成的多模态智能问答系统设计与实现 · 石墨冷峻主题

- 1 Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]. NeurIPS, 2020.
- 2 Reimers N, Gurevych I. Sentence-BERT: Sentence embeddings using siamese BERT-networks[C]. EMNLP, 2019.
- 3 Karpukhin V, Oğuz B, Min S, et al. Dense passage retrieval for open-domain question answering[C]. EMNLP, 2020.
- 4 Robertson S, Zaragoza H. The probabilistic relevance framework: BM25 and beyond[J]. Foundations and Trends in Information Retrieval, 2009.
- 5 Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. NeurIPS, 2017.